MODEL DUE DILIGENCE · 2026-11-09

DeepSeek-V4-Pro-Qwen3.5-9B
UNCENSORED-heretic

模型调查报告：谱系、架构、去审查方法、基准复核与部署评估

模型仓库	xtools-at/DeepSeek-V4-Pro-Qwen3.5-9B-UNCENSORED-heretic
固定版本	`e4bfa83c72896cbb4990c909967d6f27bb97bac4`
参数规模	9.65B（文本主干 8.95B + 视觉 0.46B + MTP 0.24B）
权重体积	19.33 GB（BF16）
许可	Apache-2.0（权重）
调查方式	API 元数据、仓库文件、Safetensors/GGUF 头部解析、讨论区与上游项目交叉核对

> 本报告基于 2026-11-09 的公开快照。模型卡与仓库可能继续更新，引用前请重新核对 commit。报告不构成法律意见，也不构成对“去审查”用途的推荐。

目录

1. 执行摘要 3
2. 调查方法、证据等级与边界 4
3. 模型身份与仓库概况 5
4. 谱系：从 Qwen3.5 到 DeepSeek 蒸馏，再到 Heretic 6
5. 技术架构拆解 8
6. 去审查方法：Heretic 2.0 与 ARA 10
7. 仓库、权重与文件一致性核查 12
8. 基准测试复核 15
9. 推理效率分析 17
10. 部署评估 18
11. 风险、合规与伦理 22
12. 适用与不适用场景 24
13. 结论与行动建议 24
14. 附录 26

报告速览

指标	数值	含义
总参数	9.653 B	文本 8.954B + 视觉 0.456B + MTP 0.243B
BF16 权重	19.33 GB	单卡 24 GB 起
去审查改写层	16 / 32	第 9–24 层
作者报告拒答	3 / 100	原模型 100 / 100
作者报告 KL	0.0422	校准语料未公开
MMLU-Pro 平均	90.53%	3 子集 × 500 题，自报
Q4_K_M 体积	5.63 GB	社区量化，当前有 MTP 缺陷

> **阅读建议：** 时间有限时，先读第 1 章（结论）、第 8 章（基准复核）、第 11 章（风险）与第 13 章（行动清单）。第 5–7 章适合需要部署或二次开发的读者。

1. 执行摘要

1.1 一句话结论

这是一个**二次派生**的 9B 级多模态推理模型：底座是 Qwen3.5-9B，中间经过 Jackrong 用 DeepSeek-V4-Pro 生成的约 25 万条数学/STEM 数据做蒸馏与 GSPO 强化学习，最后由 xtools-at 用 Heretic 2.0 的 Arbitrary-Rank Ablation（ARA）移除拒答行为。它不是 DeepSeek 官方模型，也不是从零训练的新模型，而是一次"强底座 + 领域蒸馏 + 行为定向修改"的组合实验。

1.2 关键发现

发现	证据等级
F1 真实规模为 **9.653B 参数**（文本主干 8.954B、视觉塔 0.456B、MTP 头 0.243B），BF16 权重 **19.33 GB**；"9B"是产品档位命名。	A
F2 去审查只修改语言解码器第 **9–24 层**（32 层中的 16 层）的模块矩阵，不重训、不改词表、不改视觉塔、不改 MTP 头。	A/B
F3 作者报告拒答率从 **100/100 降到 3/100**，KL 散度 **0.0422**。该指标来自 Heretic 的关键词拒答打分器，不等于安全评测。	B
F4 数学/STEM 基准均为**作者自报**：MMLU-Pro 只取 Math/Physics/Chemistry 各 500 题；相对 Qwen3.5-9B 的 **+0.93 分在统计上不显著**（标准误约 0.77，z≈1.2）。	A/C
F5 模型卡把 Qwen3.5-9B 基线测到 **89.60**，而 Qwen 官方 MMLU-Pro 为 **82.5**，相差 7.1 分，说明评测协议明显不同；因此跨模型排名不可直接采信。	A/C
F6 最可信的差异点是**推理 token 更省**：每正确答中位 token 676，对比 Qwen3.5-9B 的 3,214；每百万 token 正确数 316.8 对 202.5。	B
F7 仓库在 2026-11-08 修复了 MTP 权重缺失；但社区 GGUF（近 30 天合计约 28.1 万次下载）仍是 10-31 的旧转换。独立解析 Q4_K_M 证实：`block_count=33`、`nextn_predict_layers=1`，但只有 `blk.0–31`、没有任何 `nextn/eh_proj` 张量，llama.cpp 会在加载时断言失败。	A
F8 许可链干净：Qwen3.5-9B 与 Jackrong 底座为 Apache-2.0，教师 DeepSeek-V4-Pro 为 MIT，本仓库声明 Apache-2.0。但"去审查"属性使其不适合无护栏的公众部署。	A
F9 缺少 `reproduce/` 清单、评测脚本、原始日志与置信区间；模型卡 38 KB，但大部分是底座模型的营销 HTML，没有本模型的用法示例。	A

> **总评：技术上有意思，证据上不够硬，工程上有明显交付瑕疵。** 适合作为消融/去审查研究与受控实验对象；不建议直接作为生产依赖，尤其不建议用于面向公众的消费级应用或受监管建议场景。

1.3 分项评级

维度	评级	理由
架构先进性	A−	Qwen3.5 的混合线性注意力 + 全注意力、原生多模态、MTP，属于 2026 年主流先进结构
文档完整性	C	关键信息散落在底座营销页；缺用法、评测配置、复现清单与限制说明
基准可信度	C+	数字具体但样本小、协议不统一、无置信区间、无原始日志
去审查效果	B	拒答率下降明显，但指标单一、提示集仅 100 条、无人工复核
工程可用性	C+	Safetensors 已修复；社区 GGUF 仍坏；`pipeline_tag` 与多模态事实不一致
可复现性	D	只有 ARA 超参数和版本号，没有可复现 manifest，无法字节级复现
许可清晰度	A−	许可链兼容；但缺 NOTICE/归属文件，去审查用途仍受平台与地方法规约束
社区热度	A−	879 likes、7,088 次仓库下载；量化版合计约 29 万次下载，实际使用入口是 GGUF

2. 调查方法、证据等级与边界

2.1 调查对象与时间

- 对象：`xtools-at/DeepSeek-V4-Pro-Qwen3.5-9B-UNCENSORED-heretic`
- 固定 commit：`e4bfa83c72896cbb4990c909967d6f27bb97bac4`（2026-11-08 03:48 UTC）
- 快照日期：2026-11-09
- 关联对象：底座 `Jackrong/DeepSeek-V4-Pro-Qwen3.5-9B`、基座 `Qwen/Qwen3.5-9B`、教师 `deepseek-ai/DeepSeek-V4-Pro`、工具 `p-e-w/heretic`、社区量化仓库 `mradermacher/*-GGUF`

2.2 使用的一手材料

材料	用途
Hugging Face Model API	下载量、点赞、创建/更新时间、tags、文件清单、commit 历史
仓库原始文件	`README.md`、`config.json`、`generation_config.json`、`tokenizer_config.json`、`model.safetensors.index.json`
Safetensors 头部	远程 Range 读取 5 个权重文件的张量名、dtype、shape，精确统计参数量
GGUF 头部	远程 Range 读取 Q4_K_M 前 16 MB，解析 metadata 与 427 个张量名，独立验证 MTP 缺陷
Hugging Face Discussions API	上游仓库与 mradermacher 量化仓库的故障报告、作者回应、修复时间线
GitHub API	Heretic 仓库星标、许可、发布版本、ARA 设计文档（PR #211）
上游模型卡	Qwen3.5-9B、DeepSeek-V4-Pro、Jackrong 蒸馏版的架构、许可、基准与训练说明

2.3 证据等级

等级	含义
A	本次调查直接读取或解析得到的事实（API、文件头、配置、张量清单）
B	作者/维护者在模型卡、README 或讨论区中的自述，尚未独立复现
C	基于公开信息的推断、统计复核或交叉比对，存在不确定性

2.4 边界与未做之事

1. **没有跑全量推理。** 权重 19.33 GB，本机为 Apple M5 / 16 GB 内存，不具备 BF16 运行条件；社区 Q4_K_M 又存在加载缺陷。报告中的能力结论均来自作者自报与静态核查，不是本次实测。
2. **没有独立重跑基准。** 没有作者的评测脚本、提示模板、随机种子与原始输出，无法复现 MMLU-Pro/GSM8K 数字。
3. **没有做安全红队。** 报告只评估“去审查”的方法与声明，不测试具体有害请求的合规性，也不提供绕过安全机制的提示。
4. **没有做法律审查。** 许可与合规部分是基于公开许可文本的技术性提示，正式商用请咨询法务。
5. **数据是快照。** 作者在 11-07 至 11-08 连续修改仓库；本报告以 `e4bfa83` 为准，早于该 commit 的量化文件不能视为同一模型。

3. 模型身份与仓库概况

3.1 身份卡

字段	值
仓库 ID	`xtools-at/DeepSeek-V4-Pro-Qwen3.5-9B-UNCENSORED-heretic`
作者	`xtools-at`（显示名 Colonel Panic）
作者画像	65 个模型、308 关注者、340 likes；方向为开放权重、本地模型、蒸馏/融合、abliteration/decensoring、嵌入式 AI
创建时间	2026-10-30 10:21 UTC
最后修改	2026-11-08 03:48 UTC
固定 commit	`e4bfa83c72896cbb4990c909967d6f27bb97bac4`
任务标签	`text-generation`（但 tags 同时含 `image-text-to-text`）
库	`transformers`
架构	`Qwen3_5ForConditionalGeneration`
基座	`Jackrong/DeepSeek-V4-Pro-Qwen3.5-9B`（finetune 关系）
许可	Apache-2.0
语言声明	en / zh / ko / ja / es / ru
近 30 天下载	7,088
点赞	879
权重精度	BF16
上下文	262,144 tokens（底座宣称可扩展至约 1.01M）
模态	文本 + 图像 + 视频 token（视觉塔保留）

3.2 命名拆解

`DeepSeek-V4-Pro-Qwen3.5-9B-UNCENSORED-heretic` 这个名字包含四层信息，但容易误导：

- **DeepSeek-V4-Pro**：指教师模型，不是本模型的架构。教师是 1.6T 总参数 / 49B 激活的 MoE，MIT 许可。
- **Qwen3.5-9B**：真正的底座架构与初始化权重来源，Apache-2.0。
- **UNCENSORED / decensored / abliterated**：表示用消融方法削弱拒答行为，不是重新做安全对齐。
- **heretic**：指使用的工具链 Heretic，不是模型系列名。

因此，把它称为“DeepSeek 模型”是不准确的；更准确的描述是“**Qwen3.5-9B 的 DeepSeek 蒸馏版，再去拒答**”。

3.3 作者与维护状态

`xtools-at` 不是 DeepSeek、Qwen 或 Jackrong 的官方账号，而是一个活跃的个人模型改造者。其仓库列表中有大量 `*-UNCENSORED-heretic` 模型，覆盖 Qwen3.5、Ministral、SmolLM3 等，说明这是一条持续的“去审查流水线”，而不是单次偶发发布。

维护状态方面：

- 10-30 发布，11-07 收到 MTP/GGUF 故障报告，11-08 连续提交修复；
- 作者回应积极，但修复方式是“从母模型补回 MTP 张量”，并未重新生成量化；
- 截至 11-09，上游 Safetensors 已一致，社区 GGUF 仍旧，存在“仓库已修、下游仍坏”的错位。

4. 谱系：从 Qwen3.5 到 DeepSeek 蒸馏，再到 Heretic

4.1 三代谱系

```
Qwen/Qwen3.5-9B                    2026-02-27   Apache-2.0
   │  原生多模态、混合线性注意力、262K 上下文、MTP
   ▼
Jackrong/DeepSeek-V4-Pro-Qwen3.5-9B   2026-07-19   Apache-2.0
   │  ~250K 数学/STEM 样本 SFT + GSPO 轻量 RL
   │  教师：DeepSeek-V4-Pro（1.6T 总参 / 49B 激活，MIT）
   ▼
xtools-at/...-UNCENSORED-heretic     2026-10-30   Apache-2.0
   │  Heretic v2.0.0.dev0，ARA 消融第 9–24 层
   ▼
社区量化（GGUF / NVFP4 / MLX）          2026-10-31 起
```

4.2 教师模型：DeepSeek-V4-Pro

项目	数据
总参数	1.6T
激活参数	49B
结构	MoE，61 层，384 路由专家，每 token 激活 6 个
上下文	1,048,576 tokens
许可	MIT
官方定位	百万 token 级高效推理

教师规模是学生的约 170 倍（按总参数）或 5 倍（按激活参数）。用这样的教师生成 25 万条数学/STEM 轨迹，再蒸馏到 9B，是 2026 年常见的“强教师—小学生”路线。

需要指出：模型卡反复出现的“**Max Effect mode**”在 DeepSeek-V4-Pro 官方模型卡中找不到定义。它更可能是数据生成时使用的推理强度/采样配置，而不是官方模型变体。报告将其视为“作者自述的数据生成设置”，不做能力承诺。

4.3 中间层：Jackrong 的蒸馏版

Jackrong 版本的关键信息：

- 约 **250,000** 条数学与 STEM 样本，强调结构化推导、领域分解、最终答案构造；
- 训练路径为 **纯 SFT → 轻量 GSPO 强化学习**；
- **没有加入代码数据**，但作者观察到编程/工具调用有轻微迁移提升；
- 作者明确说明这是“交叉迁移”，不是代码专精；
- 由于训练时 DeepSeek 已发布更强的 0731/0813 版本，代码/agent 数据尚未纳入，后续会迭代。

这意味着本模型的“编程能力提升”没有专门的代码监督支撑，不能当作代码模型使用。

4.4 工具层：Heretic

项目	数据
仓库	`p-e-w/heretic`
定位	免训练语言模型行为修改（去审查、去 slop、降谄媚等）
许可	AGPL-3.0
星标	40,062
Fork	4,576
创建	2025-09-21
v2.0.0 发布	2026-11-01
v2.1.0 发布	2026-11-08
本模型使用版本	`v2.0.0.dev0`（正式版发布前 2 天）

Heretic 的默认目标是“去拒答”，默认打分器是**关键词拒答率**与 **KL 散度**，优化器是 Optuna 的 TPE。它支持可复现 manifest（`reproduce/reproduce.json`），但本仓库没有包含。

4.5 量化分发：真正的使用入口

仓库	近 30 天下载	点赞	最后修改
`mradermacher/...-i1-GGUF`	136,706	189	2026-10-31
`mradermacher/...-GGUF`	144,783	46	2026-10-31
`Sakura721/...-GGUF`	4,621	7	—
`share72/...-i1-GGUF`	3,562	0	—
原仓库 Safetensors	7,088	879	2026-11-08

两个主要 GGUF 仓库合计 **281,489** 次下载，是原仓库的约 40 倍。这说明：

1. 绝大多数用户并不直接跑 BF16 Safetensors，而是用 4-bit/8-bit 量化在本地推理；
2. 因此 **GGUF 的 MTP 缺陷影响面远大于原仓库**；
3. 社区量化的质量、许可与安全性，实际上决定了这个模型的真实口碑。

5. 技术架构拆解

5.1 关键配置

配置项	值	说明
架构	`Qwen3_5ForConditionalGeneration`	原生多模态生成模型
文本层数	32	24 层线性注意力 + 8 层全注意力
全注意力间隔	每 4 层一次	第 3、7、11、…、31 层为 full attention
隐藏维度	4,096	
Q / KV 头数	16 / 4	GQA
Head dim	256	
部分旋转	0.25	RoPE 仅作用于 64 维
RoPE theta	10,000,000	长上下文
M-RoPE	interleaved，11/11/10	多模态位置编码
FFN 中间维	12,288	SwiGLU
词表	248,320	padding 到 248,320
上下文	262,144	原生
视觉塔	27 层，hidden 1152，patch 16，merge 2	输出 4096 维
MTP	1 层，243M 参数	投机解码草稿头
精度	BF16	
注意力输出门	开启	Q 投影输出 8192 维（query + gate）

5.2 参数分布（本次实测）

通过远程读取 5 个 Safetensors 文件的头部并累加 shape，得到精确参数量：

组件	参数量	占比
文本 MLP（32 层 × 151M）	4.832 B	50.1%
词嵌入 + LM head	2.034 B	21.1%
线性注意力（24 层）	1.618 B	16.8%
全注意力（8 层）	0.470 B	4.9%
视觉塔	0.456 B	4.7%
MTP 头	0.243 B	2.5%
合计	**9.653 B**	**100%**

拆分口径：

- **主模型（文本 + 视觉）**：9.410B，与 `index.json` 的 `total_parameters` 一致；
- **文本主干**：8.954B；
- **MTP 头**：0.243B（单独文件，不计入主模型 metadata）；
- **完整 checkpoint**：9.653B。

这也解释了为什么“9B”模型的实际权重是 19.33 GB：BF16 下 9.653B × 2 字节 ≈ 19.31 GB，加上文件头与对齐，正好 19.33 GB。

5.3 混合注意力：为什么长上下文更省

Qwen3.5 的文本层不是传统 Transformer 的“32 层全注意力”，而是：

- **24 层 Gated DeltaNet 线性注意力**：维护固定大小的递归状态，序列越长，状态不增长；
- **8 层全注意力**：每 4 层插入一次，负责精确的全局检索与长程依赖；
- **注意力输出门**：Q 投影同时产生 query 与 gate，提升表达力；
- **M-RoPE**：把位置编码拆分到时间/高/宽三个方向，适配图像与视频 token。

对部署的直接后果是 KV Cache 只来自 8 层全注意力：

```
每 token 每层 KV = 2（K,V）× 4 头 × 256 维 × 2 字节 = 4 KB
8 层合计 = 32 KB / token
32K 上下文 ≈ 1.07 GB
128K 上下文 ≈ 4.29 GB
262K 上下文 ≈ 8.59 GB
```

相比 32 层全注意力的同规模模型，KV Cache 降到约 1/4。这是本模型在长上下文场景下真正的架构优势，与“去审查”无关。

5.4 MTP：0.243B 的投机解码头

MTP（Multi-Token Prediction）是挂在主模型上的一个单层草稿头，用来一次预测多个未来 token，配合投机解码提升吞吐。它的形状包括：

- `mtp.fc.weight`：4096 × 8192
- `mtp.layers.0.self_attn.q_proj.weight`：8192 × 4096（含输出门）
- `mtp.layers.0.mlp.*`：4096 ↔ 12288
- 两个 RMSNorm、q_norm/k_norm 等

关键点：作者明确说“Heretic 会忽略这些张量”，所以 **MTP 头是从母模型原样补回的，没有经过消融**。这既意味着投机解码行为不受去审查影响，也意味着 MTP 与主模型的行为一致性没有经过重新验证。

5.5 视觉塔：保留了，但没被评测

配置里有完整的 27 层视觉塔（hidden 1152、patch 16、spatial merge 2、输出 4096），权重中也有 333 个视觉张量。理论上它仍然是原生多模态模型，可以处理图像与视频 token。

但模型卡：

- 没有任何视觉基准（MMMU、DocVQA、ChartQA 等）；
- 没有图像输入示例；
- 没有说明 ARA 是否影响跨模态对齐。

因此，**视觉能力应视为“继承但未验证”**。如果你的场景依赖图像理解，必须自己补测，不能假设它与 Qwen3.5-9B 等价。

5.6 架构评价

优点：

- 混合线性注意力在长上下文下显著降低 KV 成本；
- 原生多模态，不需要外挂视觉编码器；
- MTP 为高吞吐服务提供了可选的加速路径；
- 32 层 / 4096 隐藏维度的 9B 稠密模型，单卡可部署，工程门槛低于 MoE。

代价：

- 线性注意力层对推理框架的实现质量敏感，不同后端的速度差异可能大于全注意力模型；
- 8 层全注意力仍然承担主要检索职责，超长上下文的质量取决于这 8 层；
- 视觉塔与 MTP 增加了权重体积和加载复杂度；
- `transformers 5.20.2` 是很新的版本，旧栈可能不兼容。

6. 去审查方法：Heretic 2.0 与 ARA

6.1 Heretic 的工作流

Heretic 不是训练，而是“行为定向修改”。它的基本循环是：

1. **准备对比提示**：一组“无害”提示与一组“有害/应拒答”提示；
2. **打分**：用 scorer 计算拒答率、KL 散度，或自定义指标；
3. **优化**：Optuna 的 TPE 在超参数空间里采样；
4. **修改**：modifier 根据参数直接改写模型权重矩阵；
5. **评估**：重复 2–4，直到拒答率下降且 KL 可控；
6. **保存/上传**：可选生成可复现 manifest。

Heretic 2.0 提供两种 modifier：

- **ARA（Arbitrary-Rank Ablation）**：2.0 的默认方法，专为 Heretic 开发；
- **Directional ablation / abliteration**：经典的拒答方向投影，支持 projected abliteration 与 norm preservation（MPOA）。

本模型使用的是 **ARA**。

6.2 ARA 的三个目标

根据 Heretic 作者在 PR #211 中的说明，ARA 不假设拒答方向、不假设秩，而是用 PyTorch hooks 捕获每个 Transformer 模块的输入/输出，然后直接优化模块矩阵。目标函数同时包含三项：

1. **保留无害行为**：对“无害”提示，模块输出尽量不变；
2. **拉近有害与无害**：对“有害”提示，输出尽量接近“无害”提示的输出；
3. **过度校正**：对“有害”提示，输出尽量远离它原先的输出，以突破更复杂的拒答机制。

目标函数是仿射凸的，初始矩阵已接近最优，因此 L-BFGS 通常 2–3 次迭代收敛；矩阵逐个优化，显存开销只比普通 abliteration 略高。ARA 的优点是自由度更高、不需要指定拒答流形的秩；代价是每次试验仍以拒答计数为主，调参时间不短。

6.3 本模型的 ARA 参数

参数	值	可能含义（按命名推断）
`start_layer_index`	9	从第 9 层开始修改
`end_layer_index`	24	到第 24 层结束
`preserve_good_behavior_weight`	0.8264	保留无害行为的权重较高
`steer_bad_behavior_weight`	0.0003	对“坏行为”直接引导的权重很低
`overcorrect_relative_weight`	0.9645	过度校正权重很高
`neighbor_count`	12	相邻层核宽度为 12

解读：

- **修改 16/32 层**，集中在中后段。这与“拒答表征在中后层更线性可分”的常见观察一致；
- `preserve_good_behavior_weight` 高、`steer_bad_behavior_weight` 低、`overcorrect_relative_weight` 高，说明优化器更偏向“保留原能力 + 用过校正推开拒答方向”，而不是强行把有害输出拉向某个目标；
- `neighbor_count=12` 表示消融并非只作用于单层，而是有跨层平滑，避免某一层被过度破坏。

这些解释是从参数名与 ARA 论文摘要推断的，作者没有在模型卡中逐项解释。

6.4 效果数据

指标	本模型	原模型（Jackrong 版）
拒答	3/100	100/100
KL 散度	0.0422	0（定义上）

怎么理解：

- **3/100** 意味着在 Heretic 的 100 条测试提示上，仍有 3 条被拒绝；不是“完全无拒答”，也不是“对任意有害请求都会服从”。
- **100/100** 的原模型拒答率异常整齐，说明测试提示很可能集中在明显触发拒答的类别；这不代表原模型对所有正常问题都拒答。
- **KL 0.0422** 是在某个校准语料上的平均分布偏移。0.04 量级不算“零损伤”，但在 Heretic 的实践中属于可接受范围；具体语料未公开。
- 这两个指标都来自**关键词拒答打分器**，不是人类评估，也不是 HarmBench/AdvBench 等标准安全基准。

6.5 改了什么、没改什么

组件	是否修改	说明
语言解码器第 9–24 层	是	ARA 直接改写模块矩阵
语言解码器第 0–8、25–31 层	否	保留原权重
词嵌入 / LM head	否	词表与输出分布不变
视觉塔	否	333 个视觉张量原样保留
MTP 头	否	作者明确说 Heretic 忽略 MTP，后从母模型补回
分词器 / chat template	否	chat template 与底座字节一致
训练数据 / 知识	否	没有新训练，不增加新知识

这意味着：

- 模型的**知识边界**仍由 Qwen3.5-9B + Jackrong 蒸馏决定；
- 去审查改变的是**行为倾向**，不是能力；
- 如果底座本身不会某道数学题，去审查也不会让它会；
- 视觉与 MTP 未被消融，但也没有被重新对齐。

6.6 可复现性

Heretic 支持在模型仓库中放置 `reproduce/reproduce.json`，记录环境、配置、哈希，使他人可以在几分钟内重建（不重跑数小时优化）。本仓库**没有** `reproduce/` 目录，只有 README 中的 6 个 ARA 参数和版本号。

后果：

- 你无法验证“这 6 个参数 + 这个版本”是否真的生成了当前权重；
- 你无法判断作者是否在最终保存前做了额外合并、缩放或选择性替换；
- 不同人按同样参数重跑，可能得到不同结果（PyTorch 非确定性、硬件差异）。

因此，本模型的“可复现”仅限于“知道用了什么方法”，不等于“能重建同一模型”。

7. 仓库、权重与文件一致性核查

7.1 文件清单

文件	大小	用途
`README.md`	38.6 KB	模型卡（大部分为底座营销 HTML）
`config.json`	3.0 KB	架构配置
`generation_config.json`	142 B	生成默认参数
`tokenizer.json`	20.0 MB	分词器
`tokenizer_config.json`	1.2 KB	特殊 token、chat template 配置
`vocab.json`	5.23 MB	词表
`added_tokens.json`	904 B	额外 token
`chat_template.jinja`	8.7 KB	对话模板
`preprocessor_config.json`	781 B	图像预处理
`processor_config.json`	1.3 KB	多模态处理器
`video_preprocessor_config.json`	817 B	视频预处理
`special_tokens_map.json`	876 B	特殊 token 映射
`model-00001-of-00004.safetensors`	4.94 GB	文本/视觉权重分片 1
`model-00002-of-00004.safetensors`	4.99 GB	分片 2
`model-00003-of-00004.safetensors`	4.95 GB	分片 3
`model-00004-of-00004.safetensors`	3.93 GB	分片 4
`model-mtp.safetensors`	486.6 MB	MTP 头（15 个张量）
`model.safetensors.index.json`	70.2 KB	权重索引
合计	**19.33 GB**	

7.2 一致性检查

检查项	结果	判定
索引键数	775	与母模型一致
MTP 键数	15	已恢复
视觉张量	333	与底座一致
MTP 文件张量	15，BF16，243,290,624 参数	与 `mtp_num_hidden_layers=1` 一致
主模型参数	9,409,813,744	与 `index.json` metadata 一致
总参数	9,653,104,368	含 MTP
词表	248,320	与 config 一致
EOS	`<|im_end|>`	与 generation_config 一致
PAD	`<|vision_pad|>`	多模态 padding
最大长度	262,144	与 config 一致
config 与底座差异	仅序列化字段（dtype/torch_dtype、视觉 rope、partial_rotary 嵌套）	架构未变

结论：**当前 commit 的 Safetensors 仓库在结构上是自洽的。**MTP 张量已补回，索引、config、文件三者匹配。

7.3 MTP 事故时间线

时间（UTC）	事件
2026-10-30 10:21	仓库创建，发布 9B heretic 模型
2026-10-31 09:45	mradermacher 发布 i1 GGUF 量化
2026-11-07 09:12	用户 `istone` 报告：GGUF 声明 MTP 但缺张量，llama.cpp 断言失败
2026-11-07 10:21	中文用户报告 LM Studio 加载失败、缺 MTP
2026-11-07 12:56	作者回复“周一来看”
2026-11-08 02:05–03:48	作者连续更新 README、config、补回 MTP 张量
2026-11-08 03:36	commit：`Restore MTP tensors from the original model`
2026-11-08 03:48	commit：`Update config.json`，恢复 `mtp_num_hidden_layers=1`
2026-11-08 13:07	作者称测试 mradermacher 量化“未遇到崩溃”，但承认未覆盖所有后端
2026-11-09	社区 GGUF 仍为 10-31 版本，未重新转换

7.4 独立验证：Q4_K_M 仍然是坏的

本次调查远程读取了 `mradermacher/...-GGUF` 的 `Q4_K_M` 文件前 16 MB，解析 GGUF v3 头部，得到（下表键名省略 `qwen35.` 前缀）：

项目	实测值	应有值	判定
文件大小	5,629,111,264 B（5.63 GB）	—	—
张量数	427	427（无 MTP）	—
`general.architecture`	`qwen35`	`qwen35`	OK
`block_count`	**33**	32（无 MTP）或 33（含 MTP）	与张量不符
`nextn_predict_layers`	**1**	1	与张量不符
`context_length`	262,144	262,144	OK
`attention.recurrent_layers`	33 项	32 项	多 1 项
`blk.32.*`	**不存在**	若 block_count=33 则应存在	缺失
`nextn` / `eh_proj`	**0 个**	若 nextn=1 则应存在	缺失
`blk.*` 最大编号	31	31	只有 32 层
视觉张量	0（`mmproj` 单独文件）	单独文件	OK

llama.cpp 的 `qwen35.cpp` 在加载时会检查 `layer.nextn.eh_proj`，缺失即触发：

```
GGML_ASSERT(layer.nextn.eh_proj && "MTP block missing nextn.eh_proj") failed
```

这不是显存不足，也不是量化类型问题；它在分配显存之前就会崩溃。**所有基于 10-31 旧权重转换的 GGUF，包括 i1 与非 i1，都受影响。**

作者在 11-08 修复了上游 Safetensors，但没有重转量化。因此：

- 直接加载原仓库 BF16：应正常；
- 加载社区 GGUF：仍可能崩溃；
- 需要等 mradermacher 等维护者从 `e4bfa83` 重新转换，或自己转。

7.5 其他交付瑕疵

1. **`pipeline_tag` 与事实不符**：写的是 `text-generation`，但模型是 `image-text-to-text`，tags 里也同时有 `image-text-to-text`。
2. **模型卡缺用法**：没有 `from transformers import ...` 示例，没有 vLLM/llama.cpp 命令，没有 system prompt 建议，没有 thinking 模式说明。
3. **模型卡主体是底座营销页**：38 KB 中大部分是 Jackrong 的 HTML 模板，包含外部链接、徽章、游戏展示；真正属于 heretic 的内容只有开头两段和 6 个参数。
4. **语言声明不完整**：只列 6 种语言，但 Qwen3.5 官方支持 201 种；这是沿用了蒸馏版的声明，未做多语言评测。
5. **`transformers_version` 过新**：`5.20.2`，旧环境可能无法加载。
6. **MTP 文件名不遵循分片模式**：`model-mtp.safetensors` 不在 `model-0000X-of-00004` 序列里；依赖 glob 的工具可能漏掉，依赖 index 的工具则正常。
7. **缺 NOTICE/归属文件**：Apache-2.0 要求保留版权与许可声明，仓库只有 README 文字提及上游。
8. **缺安全/限制章节**：模型卡的“Limitations”是底座模型的通用限制，没有针对“去审查”的额外风险说明。

8. 基准测试复核

8.1 作者给出的 GSM8K

评测配置：NVFP4（FP8 E4M3）量化、vLLM、GSM8K 测试集跑 4 次取平均。

模型	准确率
MiMo-V2.5-Pro	99.60%
Llama-3.1-405B-Instruct	96.80%
Llama-3.3-70B-Instruct	94.84%
DeepSeek-V4-Pro-Qwen3.5-9B	**94.50%**
DeepSeek-V4-Pro（教师）	92.60%
DeepSeek-V3	89.30%

作者说“9B 学生略超教师，接近 Llama-3.3-70B”。这句话有三个问题：

1. **教师分数来自不同来源**：作者注明其他模型的参考分来自 `openai/gsm8k` 仓库，而不是在同一 harness 下重跑；
2. **4 次平均不是独立样本**：同一测试集跑 4 次只降低采样噪声，不消除协议差异；
3. **94.50 vs 94.84 的 0.34 分差距远小于噪声**，不能支撑“接近 70B”的排名结论。

8.2 作者给出的 MMLU-Pro

评测配置：Math / Physics / Chemistry 各 500 题，共 1,500 题；llama.cpp；MTP-Q8_0 GGUF，8K 上下文。

模型	构建	Math	Physics	Chemistry	平均
DeepSeek-V4-Pro-Qwen3.5-9B	MTP-Q8_0 GGUF	**92.40**	**89.40**	**89.80**	**90.53**
Qwen3.5-9B	MTP-Q8_0 GGUF	90.60	89.00	89.20	89.60
Claude Mythos-distilled 27B	MTP-Q8 GGUF	88.40	87.60	82.60	86.20
Claude Mythos-distilled 9B	MTP-Q8_0 GGUF	86.00	78.60	78.60	81.07
DeepSeek-V4-Pro-Qwen3.5-4B	MTP-Q8 GGUF	80.40	74.20	74.80	76.47

相对 Qwen3.5-9B：Math +1.80、Physics +0.40、Chemistry +0.60、平均 +0.93。

统计显著性

对每个子集 n=500、p≈0.9：

```
单子集标准误 SE = sqrt(0.9 × 0.1 / 500) ≈ 1.34 个百分点
三子集平均 SE ≈ 1.34 / sqrt(3) ≈ 0.77 个百分点
差值 0.93 → z ≈ 1.2，双侧 p ≈ 0.23
95% 置信区间约 ±1.5 个百分点
```

也就是说，**+0.93 分的“平均最高”在统计上无法与“持平”区分**。如果真实准确率更接近 0.8，标准误还会更大（单子集 1.79，平均 1.03），显著性更弱。

作者没有报告方差、置信区间或随机种子，也没有说明 500 题是如何抽样的。MMLU-Pro 每个子集有数百到上千题，抽 500 题若不固定种子，换一批题就可能改变排名。

8.3 评测协议不一致

这是最严重的问题。Qwen 官方模型卡给出的 Qwen3.5-9B MMLU-Pro 是 **82.5**；本模型卡在同一列写的是 **89.60**，相差 **7.1 分**。

可能原因：

- 官方用完整 MMLU-Pro（或不同的 few-shot/CoT 协议），作者只取 3 个 STEM 子集；
- 官方用 0-shot 直接答题，作者用 8K 上下文的 MTP-Q8_0；
- 答案提取、系统提示、thinking 模式开关不同；
- 量化与后端不同。

无论原因是什么，结论都一样：**不能用这张表去和其他论文/模型卡的数字横向比较**。表内的 Qwen 基线是作者自己重测的，不是官方数字；表外的 Llama、DeepSeek、Claude Mythos 又是从不同来源拼来的。把三者放在同一张表里排名，方法上不成立。

另外，“Claude Mythos-distilled 27B/9B”不是常见的公开基线，无法从名称定位到可核验的模型卡；这类对比应视为作者自建参考，而非行业基准。

8.4 缺失的评测

模型卡声称“数学/STEM 推理”，但没有给出：

- MATH-500、AIME 2024/2025、GPQA、OlympiadBench；
- MMLU-Pro 全量（14 个子集）或 MMLU 全量；
- LiveCodeBench、HumanEval、SWE-bench（作者自己说没有代码数据）；
- 安全基准：HarmBench、AdvBench、ToxiGen、XSTest；
- 多语言基准：C-Eval、M-MMLU、M-RoPE 长上下文；
- 视觉基准：MMMU、DocVQA、ChartQA；
- 长上下文“大海捞针”与多跳检索；
- 校准/拒答权衡曲线。

因此，现有证据只能支持一个弱结论：**它在 GSM8K 和 MMLU-Pro 的三个 STEM 子集上可能略有提升**，不足以支持“全面 STEM 更强”或“接近 70B”的说法。

8.5 指令遵循

作者报告：在 1,500 道 MMLU-Pro 题上，要求“思考后只输出一个大写字母”，本模型 **97.2%** 给出单个字母，只有 **0.2%** 冗长复述；Qwen3.5-9B 官方为 37.3% / 62.1%，Claude Mythos-distilled 9B 为 69.6% / 21.1%。

这个结果如果属实，是比 +0.93 分更有价值的差异：蒸馏模型学会了“按格式收尾”，对生产环境的解析友好。但它：

- 不是标准 IFEval/IFEval-CN；
- 没有给出评分 rubric 与人工抽检；
- 对比模型的 system prompt 是否完全一致未说明；
- 只测了一种格式（单字母），不能外推到 JSON、表格、工具调用。

8.6 基准复核结论

声明	证据等级	复核意见
GSM8K 94.50%	B/C	数字具体，但参考分来自不同协议；0.34 分差距无意义
MMLU-Pro 平均 90.53%	B/C	3 子集 × 500 题；+0.93 不显著；与官方 Qwen 82.5 差 7.1 分，协议不一致
每正确答 token 少 36.1%	B	方向可信，但依赖正确集与分词口径
格式遵循 97.2%	B	有生产价值，但非标准基准，需自测
“接近 Llama-3.3-70B”	C	不在同一 harness，不能这样比
“超越教师”	C	教师分数来自第三方参考，不是同协议重跑

建议：把这些数字当作“作者声称”，不要写进采购决策或对外宣传。 如果要用，必须用自己的 1,000+ 题、固定种子、同一 harness 重跑，并报告均值 ± 95% CI。

9. 推理效率分析

9.1 Token 经济性

作者在同一 1,500 题 MMLU-Pro 样本上统计：

模型	准确率	平均推理 token/题	中位 token/正确答	每百万 token 正确数
本模型	90.53%	2,858	**676**	**316.8**
Qwen3.5-9B	89.60%	4,425	3,214	202.5
Claude Mythos-distilled 9B	81.07%	3,310	639	244.9

作者给出的相对变化：

- 对比 Qwen3.5-9B：每正确答 token 少 **36.1%**，准确率 +0.93；
- 对比 Mythos 9B：少 **22.7%**，准确率 +9.47；
- 每百万 token 正确数：比 Qwen 高 **56.4%**，比 Mythos 高 **29.3%**。

分学科 token 节省（对比 Qwen / Mythos）：

学科	vs Qwen	vs Mythos
Math	47.4%	35.6%
Physics	30.8%	10.8%
Chemistry	32.1%	23.3%

9.2 怎么解读

这是整份模型卡里**最可信、也最有价值**的部分，原因：

1. 它不是“准确率更高”，而是“同样答对时更省 token”，这类指标不容易被采样噪声左右；
2. 中位数 676 vs 3,214 的差距极大（约 4.8 倍），说明本模型在简单题上更果断，不会像底座那样长篇自我怀疑；
3. 每百万 token 正确数同时受准确率与 token 长度影响，作者把两个维度都列出来了，口径相对清楚。

但仍有三个注意点：

- **平均值 2,858 vs 中位数 676**：分布严重右偏，少数超长推理拉高了均值；对成本敏感的线上服务，应按 P90/P99 而不是均值做容量规划。

- **“每正确答 token”依赖正确集**：如果准确率被高估，分母变小，效率会被高估；两者不是独立指标。
- **分词器相同**（同一 Qwen 词表），所以 token 比较是公平的；但不同后端（vLLM vs llama.cpp）对 thinking token 的截断/解析可能不同。

GSM8K 的 NVFP4 轨迹统计（2,638 条）：平均 1,627 token、中位 372、P90 3,042、每正确答 1,721。与 MMLU-Pro 的结论一致：**简单题很短，难题会展开**。

9.3 推理性能因素

因素	影响
混合注意力	KV Cache 只有 8 层，长上下文显存约为同规模全注意力模型的 1/4
MTP	投机解码可提升 decode 吞吐，但取决于草稿接受率；官方未给本模型的加速比
262K 上下文	权重 + KV 在 BF16 下约 27.9 GB（262K 时），单卡 24 GB 不够
量化	Q4_K_M 权重 5.63 GB，但数学精度会下降；需在自己的题集上重测
后端	vLLM/SGLang 对 Qwen3.5 的支持来自 main 分支；llama.cpp 的 qwen35 实现较新，版本差异大

10. 部署评估

10.1 硬件矩阵（估算）

假设：BF16 权重 19.33 GB；KV Cache 按 8 层全注意力、BF16、4 KV 头 × 256 维计算；预留 10–20% 激活/碎片开销。

格式	权重	32K KV	128K KV	262K KV	建议硬件
BF16	19.33 GB	1.07 GB	4.29 GB	8.59 GB	24 GB 紧；32 GB 舒适；262K 需 40 GB+
FP8	~9.7 GB	0.54 GB	2.15 GB	4.30 GB	16 GB（32K）；24 GB（128K）
NVFP4	~5.0 GB	1.07 GB	4.29 GB	8.59 GB	12 GB（32K）；24 GB（128K）
Q8_0 GGUF	9.53 GB	1.07 GB	4.29 GB	8.59 GB	16 GB（32K）；24 GB（128K）
Q4_K_M GGUF	5.63 GB	1.07 GB	4.29 GB	8.59 GB	8–12 GB（32K）
IQ4_XS GGUF	5.23 GB	1.07 GB	4.29 GB	8.59 GB	8–12 GB（32K）

注：

- NVFP4 需要 Blackwell 级 GPU（RTX 50 系 / B200 等）；老卡不支持。
- GGUF 的 KV 精度可设为 Q8/Q4，能进一步减半，但会损失长上下文质量。
- GGUF 的视觉能力需另加 `mmproj`：Q8_0 约 0.62 GB，F16 约 0.92 GB；表内 GGUF 体积仅指主模型。
- MTP 头额外 0.49 GB；不用 MTP 可忽略。
- 以上是单序列估算；批量服务需按并发数乘 KV。

10.2 推荐路径

场景	推荐	理由
NVIDIA GPU、追求吞吐	vLLM / SGLang（main 分支）	支持 Qwen3.5、连续批处理、MTP、OpenAI API
Apple Silicon / CPU	llama.cpp（最新构建）	Metal/CPU 友好；等 GGUF 重转后再用
单机实验	Transformers + BF16	最简单，但 19.33 GB 权重，需 24 GB+
边缘设备	Q4_K_M / IQ4_XS	5–6 GB；但当前量化损坏，需自转
Mac 16 GB	4B 兄弟版更现实	9B Q4 约 5.6 GB 可加载，但长上下文与质量受限

10.3 Transformers 示例

以下示例按 Qwen3.5 的通用接口编写；不同 `transformers` 版本可能使用 `AutoModelForImageTextToText` 或 `Qwen3_5ForConditionalGeneration`，以实际版本为准。

```
from transformers import AutoProcessor, AutoModelForImageTextToText
import torch

model_id = "xtools-at/DeepSeek-V4-Pro-Qwen3.5-9B-UNCENSORED-heretic"

processor = AutoProcessor.from_pretrained(model_id)
model = AutoModelForImageTextToText.from_pretrained(
    model_id,
    dtype=torch.bfloat16,
    device_map="auto",
)

messages = [
    {"role": "system", "content": "You are a careful math and STEM assistant. Show your
reasoning, then give the final answer."},
    {"role": "user", "content": [{"type": "text", "text": "Solve: ..."}]},
]

inputs = processor.apply_chat_template(
    messages,
    add_generation_prompt=True,
    tokenize=True,
    return_dict=True,
    return_tensors="pt",
).to(model.device)

with torch.no_grad():
    output = model.generate(
        **inputs,
        max_new_tokens=2048,
        do_sample=False,
    )

print(processor.decode(output[0][inputs["input_ids"].shape[-1]:], skip_special_tokens=True))
```

注意：

- 模型默认是 thinking 模式，输出 `<think>...</think>`；生产解析要能处理这段。
- 若显存不足，先降 `max_model_len`，不要先降精度。
- 多模态输入需要 `processor` 处理图像/视频，文本-only 场景可只传 text content。

10.4 vLLM 示例

```
# 需要支持 Qwen3.5 的 vLLM（main / nightly）
vllm serve xtools-at/DeepSeek-V4-Pro-Qwen3.5-9B-UNCENSORED-heretic \
  --max-model-len 32768 \
  --reasoning-parser qwen3 \
  --port 8000

# 启用工具调用（如需要）
vllm serve xtools-at/DeepSeek-V4-Pro-Qwen3.5-9B-UNCENSORED-heretic \
  --max-model-len 32768 \
  --reasoning-parser qwen3 \
  --enable-auto-tool-choice \
  --tool-call-parser qwen3_coder \
  --port 8000
```

MTP 投机解码的开启方式随 vLLM 版本变化，需查阅对应版本文档；不要假设 `--speculative-*` 参数在本模型上一定生效。

10.5 llama.cpp 示例与验证

```
# 前提：GGUF 已从修复后的 safetensors 重新转换
llama-server \
  -m DeepSeek-V4-Pro-Qwen3.5-9B-UNCENSORED-heretic.Q4_K_M.gguf \
  --mmproj DeepSeek-V4-Pro-Qwen3.5-9B-UNCENSORED-heretic.mmproj-f16.gguf \
  -c 32768 \
  -ngl 99 \
  --host 127.0.0.1 --port 8080
```

加载前先验证 GGUF 元数据与张量是否一致：

```
import struct, json

path = "model.Q4_K_M.gguf"
with open(path, "rb") as f:
    magic, version, n_tensors, n_kv = struct.unpack("<IIQQ", f.read(24))
    # 省略 KV 解析；可用 gguf_dump.py / llama-gguf 工具
    print("tensors:", n_tensors)
```

更简单的办法是用 `llama.cpp` 自带的 `gguf_dump.py` 或 `llama-gguf` 查看：

```
python gguf_dump.py model.Q4_K_M.gguf | grep -E "block_count|nextn_predict_layers"
```

判定规则：

- 若 `block_count=33` 且 `nextn_predict_layers=1`，必须存在 `blk.32.*` 与 `nextn/eh_proj` 张量；否则会崩溃。
- 若没有 MTP，转换前把 `config.json` 的 `mtp_num_hidden_layers` 设为 `0`，并把 `nextn_predict_layers` 置 0。

10.6 本机可行性（Apple M5 / 16 GB）

- BF16：不可行（19.33 GB 权重 + KV）。
- Q8_0：9.53 GB 权重，16 GB 统一内存可加载，但 32K 上下文会紧张。
- Q4_K_M：5.63 GB 权重，理论可行；但当前社区 GGUF 因 MTP 缺陷会在 llama.cpp 加载时崩溃。
- 4B 兄弟版：更现实的选择；`xtools-at/DeepSeek-V4-Pro-Qwen3.5-4B-UNCENSORED-heretic` 已于 11-02 发布，文件结构类似，也带 `model-mtp.safetensors`。

本次调查**没有在本机执行推理**，因为需要先解决 GGUF 重转或下载 19 GB BF16 权重；上述为容量推算，不是实测帧率。

11. 风险、合规与伦理

11.1 安全风险

这是本模型最需要明确提示的部分。

风险	说明	缓解
拒答被削弱	作者目标就是把拒答从 100/100 降到 3/100；剩余 3% 不代表安全边界	外部审核、允许列表、输出过滤
有害内容合规	模型可能配合生成违法/有害内容；没有任何内置 guardrail	不要面向公众裸露；加系统提示与分类器
幻觉	数学/STEM 仍会算错；作者自己列为限制	工具校验、双模型复核、人工抽检
多模态攻击面	视觉塔保留但未评测；图像输入可能绕过文本过滤	图像审核、OCR/内容分类
提示注入	长上下文 + 工具调用场景下，外部内容可注入指令	隔离不可信内容、工具权限最小化
过度服从	去审查可能同时削弱“拒绝不安全请求”的能力	红队测试、拒答率/有用性权衡曲线

需要强调：**“3/100 拒答”不是“3% 有害”，也不是“97% 安全”。** 拒答率只是模型在特定提示集上说“不”的比例；它不衡量模型是否真的能造成伤害，也不衡量输出质量。

11.2 许可与法律

层	许可	结论
Qwen3.5-9B	Apache-2.0	允许商用、修改、再分发；需保留版权/许可声明
Jackrong 蒸馏版	Apache-2.0	同上
DeepSeek-V4-Pro（教师）	MIT	允许使用、修改、再分发；需保留版权/许可声明
本仓库	Apache-2.0	与上游兼容
Heretic 工具	AGPL-3.0	修改/分发工具本身需开源；模型权重是否受 AGPL 约束存在解释空间，通常视为独立作品

要点：

- **许可链是干净的**：没有看到 GPL 污染或非商用限制。
- **教师输出用于蒸馏**：DeepSeek-V4-Pro 是 MIT，未看到禁止用输出训练其他模型的条款；但正式商用仍建议让法务核对 DeepSeek 的使用条款与输出政策。

- **Apache-2.0 的义务**：分发时要附 LICENSE、保留 NOTICE/版权声明、说明修改。本仓库没有 NOTICE 文件，README 只在致谢里提到上游；如果二次分发，建议自己补齐。
- **Heretic 的 AGPL**：如果你修改 Heretic 并把它作为服务提供，AGPL 的网络使用条款可能要求开源修改；但“用 Heretic 产出的权重”不等于“Heretic 的衍生代码”。保持工具与权重分离，风险较低。
- **平台政策**：Hugging Face 允许托管，但应用商店、云厂商、支付/广告平台可能禁止“uncensored”内容；上线前逐项核对。
- **地区法规**：
  - 欧盟：AI Act 对 GPAI 的透明度、版权政策、风险评估有要求；去审查模型用于公众服务需要额外说明。
  - 中国：《生成式人工智能服务管理暂行办法》要求内容安全、标识、备案；此类无护栏模型不适合直接面向公众提供服务。
  - 美国：无统一联邦 AI 法，但 FTC Act 第 5 条、州级法律、行业监管仍适用；虚假宣传与伤害责任不能忽视。
- **出口管制**：9B 模型不属于前沿大模型，通常不受出口管制；但若用于军事/监控等敏感场景，仍需单独评估。

> 以上不是法律意见。商用前请让法务确认许可、平台条款与属地法规。

11.3 供应链风险

风险	事实	建议
非官方二次派生	个人账号的融合/消融，不是 DeepSeek/Qwen 官方	固定 commit，记录来源
无签名/无哈希	README 没有权重 sha256；只有 HF LFS 指针	下载后自行计算并存档
同名镜像多	搜索到 25+ 个同名仓库，部分 0 下载	只认 canonical repo，警惕 typosquat
量化滞后	社区 GGUF 仍是 10-31 旧权重	等重转或自转，验证元数据
MTP 文件拆分	`model-mtp.safetensors` 不在分片序列	用 index 加载；转换前检查是否被包含
模型卡外部链接	README 含大量外链/徽章	视为数据，不要在生产中自动抓取

11.4 评测与声誉风险

- 模型卡的基准是**自报**，没有第三方 leaderboard 记录；
- “Claude Mythos-distilled”基线无法定位到可核验模型卡；
- 879 likes / 7,088 下载 vs 28 万 GGUF 下载，说明热度主要来自“本地能跑”，不是“评测领先”；
- 如果你对外宣称“接近 70B”或“超越教师”，可能构成误导性宣传。

11.5 伦理

- 去审查模型的正当用途包括：安全研究、红队、内容审核器训练、文学/创作自由实验；
- 不当用途包括：面向未成年人的无护栏聊天、违法内容生成、绕过平台安全策略；
- 如果部署，至少应：披露模型来源与限制、保留日志、提供人工申诉、对高风险请求加二次审核；
- 不要用“开源”作为免除责任的理由；许可证免责条款不等于运营者无责任。

12. 适用与不适用场景

场景	建议	理由
去审查/消融方法研究	✅ 推荐	ARA + 9B 混合架构的公开案例，参数完整
安全红队与对齐研究	✅ 推荐（隔离环境）	可作为“弱拒答”被测对象；需遵守伦理审查
本地数学/STEM 助手	⚠️ 可用，需人工复核	GSM8K/MMLU-Pro 数字尚可，但无独立复现
成本敏感的推理服务	⚠️ 试点	token 效率是亮点；需按自己的题集验证
长上下文文档分析	⚠️ 试点	架构支持 262K，但没有长上下文评测
图像/视频理解	❌ 不建议	视觉塔保留但零评测
代码生成/Agent	❌ 不建议	训练无代码数据，作者自己说只有轻微迁移
消费级聊天机器人	❌ 不建议	去审查 + 无 guardrail + 合规风险
医疗/法律/金融建议	❌ 不建议	幻觉、责任、监管风险
未成年人产品	❌ 不建议	内容安全无法保证
受监管行业生产	❌ 不建议	缺安全评测、可复现性与供应商保障

13. 结论与行动建议

13.1 结论

1. **它不是“DeepSeek 官方 9B”**，而是 Qwen3.5-9B 的 DeepSeek 蒸馏版再去拒答；命名容易误导，采购/宣传时要写清楚。
2. **架构是先进的**：混合线性注意力、原生多模态、MTP、262K 上下文，9.65B 稠密规模，单卡可部署。
3. **去审查方法有技术含量**：ARA 不依赖拒答方向，直接优化模块矩阵；只改 16/32 层，KL 0.0422，思路清晰。
4. **证据质量不足**：基准自报、样本小、协议不统一、无置信区间、无原始日志、无可复现 manifest；“+0.93 分”不显著，“接近 70B”不成立。
5. **工程交付有瑕疵**：MTP 权重缺失导致社区 GGUF 崩溃；上游已修但量化未重转；模型卡缺用法与限制；`pipeline_tag` 与多模态事实不符。
6. **真正的亮点是 token 效率**：中位每正确答 676 token，对比 Qwen3.5-9B 的 3,214；如果独立复现，对成本敏感服务有价值。
7. **合规上“许可干净、用途敏感”**：Apache-2.0/MIT 链条兼容，但去审查属性不适合无护栏公众部署。

13.2 行动清单

P0：如果明天要用

1. **固定版本**：只认 `e4bfa83c72896cbb4990c909967d6f27bb97bac4`；记录下载时间与文件哈希。
2. **不要直接用旧 GGUF**：10-31 的量化全部有 MTP 元数据缺陷；要么等 mradermacher 重转，要么自己从 Safetensors 转，并在加载前验证 `block_count` / `nextn` / `blk.32`。
3. **自建评测**：至少 1,000 题、固定种子、同一 harness，对比 Qwen3.5-9B、Jackrong 底座、本模型；报告均值与 95% CI。
4. **红队 + 外部审核**：测有害请求服从率、拒答率、过度拒答；上线前加输入/输出分类器与人工申诉。

P1：如果准备试点

5. **补许可文件**：附 Apache-2.0 LICENSE、NOTICE、上游归属与修改说明。
6. **测长上下文**：32K/128K/262K 的 needle-in-a-haystack、多跳检索、成本曲线。
7. **测多模态**（如需要）：MMMU/DocVQA/ChartQA 小样本，确认视觉塔未被消融破坏。
8. **测 MTP**：草稿接受率、decode 吞吐、与不开 MTP 的质量差异。

P2：如果长期跟踪

9. **关注上游**：mradermacher 是否重转、Heretic v2.1 是否影响 ARA、模型卡是否补评测。
10. **考虑 4B 兄弟版**：16 GB 设备更现实；但同样要检查 MTP 与量化状态。
11. **建立内部模型卡**：记录来源、许可、评测、限制、责任人，避免“模型卡即营销页”。

13.3 一句话建议

> **把它当作“研究工件”而不是“生产模型”：可以研究它的 ARA 方法、token 效率和混合架构；不要把它当作 DeepSeek 官方能力、不要相信未复现的基准、不要把旧 GGUF 直接上线。**

14. 附录

附录 A：复现本次调查的关键命令

```
# 1) 读取模型元数据（需要能访问 huggingface.co）
curl -sL "https://huggingface.co/api/models/xtools-at/DeepSeek-V4-Pro-Qwen3.5-9B-UNCENSORED-heretic?blobs=true"

# 2) 读取 config / index
curl -sL "https://huggingface.co/xtools-at/DeepSeek-V4-Pro-Qwen3.5-9B-UNCENSORED-heretic/raw/main/config.json"
curl -sL "https://huggingface.co/xtools-at/DeepSeek-V4-Pro-Qwen3.5-9B-UNCENSORED-heretic/raw/main/model.safetensors.index.json"

# 3) 读取讨论区
curl -sL "https://huggingface.co/api/models/xtools-at/DeepSeek-V4-Pro-Qwen3.5-9B-UNCENSORED-heretic/discussions"
curl -sL "https://huggingface.co/api/models/mradermacher/DeepSeek-V4-Pro-Qwen3.5-9B-UNCENSORED-heretic-i1-GGUF/discussions"

# 4) 读取 commit 历史
curl -sL "https://huggingface.co/api/models/xtools-at/DeepSeek-V4-Pro-Qwen3.5-9B-UNCENSORED-heretic/commits/main"

# 5) 解析 Safetensors 头部（Range 读取，不下载全量）
python3 - <<'PY'
import json, struct, urllib.request
url = "https://huggingface.co/xtools-at/DeepSeek-V4-Pro-Qwen3.5-9B-UNCENSORED-heretic/resolve/main/model-mtp.safetensors"
n = struct.unpack("<Q", urllib.request.urlopen(urllib.request.Request(url, headers={"Range": "bytes=0-7"})).read(8))[0]
h = json.loads(urllib.request.urlopen(urllib.request.Request(url, headers={"Range": f"bytes=8-{8+n-1}"})).read())
print(h)
PY
```

附录 B：术语表

术语	含义
Abliteration	通过消融/投影移除模型拒答方向的技术
ARA	Arbitrary-Rank Ablation，Heretic 2.0 的默认消融方法，不假设拒答流形秩
KL divergence	修改前后模型输出分布的散度，越低越接近原模型
MTP	Multi-Token Prediction，多 token 预测草稿头，用于投机解码
GQA	Grouped Query Attention，分组查询注意力
Gated DeltaNet	一种线性注意力/状态空间混合结构，固定大小递归状态
M-RoPE	Multimodal RoPE，多模态旋转位置编码
NVFP4	NVIDIA 的 4-bit 浮点量化格式，需要 Blackwell 级 GPU
GGUF	llama.cpp 使用的量化模型文件格式
mmproj	多模态投影文件，配合 GGUF 主模型使用
蒸馏	用强教师模型的输出训练小学生模型
SFT	Supervised Fine-Tuning，监督微调
GSPO	Grouped Stepwise Preference Optimization，一种偏好优化方法

附录 C：参考链接

来源	链接
本模型	https://huggingface.co/xtools-at/DeepSeek-V4-Pro-Qwen3.5-9B-UNCENSORED-heretic
4B 兄弟版	https://huggingface.co/xtools-at/DeepSeek-V4-Pro-Qwen3.5-4B-UNCENSORED-heretic
Jackrong 底座	https://huggingface.co/Jackrong/DeepSeek-V4-Pro-Qwen3.5-9B
Qwen3.5-9B	https://huggingface.co/Qwen/Qwen3.5-9B
DeepSeek-V4-Pro	https://huggingface.co/deepseek-ai/DeepSeek-V4-Pro
Heretic 项目	https://github.com/p-e-w/heretic
Heretic 官网	https://heretic-project.org
ARA 设计 PR	https://github.com/p-e-w/heretic/pull/211
mradermacher GGUF	https://huggingface.co/mradermacher/DeepSeek-V4-Pro-Qwen3.5-9B-UNCENSORED-heretic-GGUF
i1 GGUF	https://huggingface.co/mradermacher/DeepSeek-V4-Pro-Qwen3.5-9B-UNCENSORED-heretic-i1-GGUF

附录 D：数据快照

字段	值
快照时间	2026-11-09
模型 commit	`e4bfa83c72896cbb4990c909967d6f27bb97bac4`
仓库文件总大小	19,331,656,186 B（19.33 GB）
主模型参数	9,409,813,744
MTP 参数	243,290,624
总参数	9,653,104,368
索引键数	775
MTP 张量数	15
视觉张量数	333
近 30 天下载	7,088
点赞	879
主要 GGUF 下载合计	281,489
原始 Q4_K_M 大小	5,629,111,264 B
Q4_K_M 张量数	427
Q4_K_M `block_count`	33
Q4_K_M `nextn_predict_layers`	1
Q4_K_M `blk.32`	不存在
Q4_K_M `nextn/eh_proj`	0

报告完。 本报告不提供有害请求的测试提示，也不建议在生产环境中关闭安全护栏。若需进一步做受控红队评测，建议在隔离环境、明确授权与伦理审查下进行。